

RESTITUTION — EXPERT TECHNIQUE IA GÉNÉRATIVE, GTAR

Hakim Arezki, PhD · Point du 8 septembre 2026

Ce que j'ai compris du besoin

Le GTAR a déployé une solution d'IA générative open source sur des serveurs on-premise. Les quatre équipes commencent à s'en saisir, et le poste est rattaché à l'équipe transverse : le mandat n'est donc pas de construire une solution de plus, mais de **faire tenir un usage partagé entre des équipes qui n'ont ni les mêmes besoins ni le même niveau de maturité**.

Trois tensions me semblent structurer la mission.

Mutualiser sans brider. Les paramétrages, System Prompts et gabarits doivent être communs pour être tenables, tout en laissant chaque équipe traiter ses cas d'usage propres — conduite, MCO, appui aux ACR.

Tenir la charge sur un parc fixe. En on-premise, on ne rajoute pas une instance quand la demande monte. L'adoption progresse, et l'infrastructure devient le facteur limitant.

Livrer transmissible. Les agents et les pipelines doivent être documentés, testés et repris en exploitation par les équipes du GTAR, dans un environnement où la sûreté de fonctionnement prime.

Ma lecture des sept objectifs

Ils se regroupent en trois blocs qui ne demandent pas les mêmes gestes.

Socle commun — objectifs 2 et 4. Paramétrages, System Prompts et gabarits mutualisés, pipelines RAG et valorisation de la connaissance. C'est la fondation : tant qu'elle n'existe pas, chaque équipe refait ses réglages dans son coin et la charge explose sans que personne ne sache pourquoi.

Cas d'usage — objectifs 3 et 5. Agents développés sur les besoins remontés, référencés et documentés au fil de l'eau. Le référencement n'est pas une tâche de fin de projet : c'est ce qui permet de savoir ce qui tourne, pour qui, à quel coût, et sous quelles obligations réglementaires.

Adoption et coordination — objectifs 1, 6 et 7. Formations de prise en main, animation de la communauté des référents techniques, coordination avec Cœur IA et Connect IA. Quatre des sept objectifs relèvent de cette dimension : c'est au moins la moitié du poste.

Où se situe généralement la saturation

Sur l'objectif 2, par ordre de fréquence sur les plateformes que j'ai industrialisées :

Servage — inférence sans batching continu : chaque requête mobilise le GPU pour elle seule, l'occupation reste basse pendant que la file s'allonge.

Modèles — un seul modèle lourd pour tous les usages, sans quantification, là où une bonne part des demandes serait traitée par un modèle plus petit.

Contexte — RAG peu sélectif et prompts longs : des milliers de tokens inutiles à chaque appel.

Cache — absence de cache sémantique sur les questions récurrentes, et cache KV non exploité entre tours.

Agents — boucles non bornées et appels en cascade : un agent mal cadré amplifie la charge d'un facteur cinq à dix.

File d'attente — ni priorisation ni dégradation gracieuse : un usage exploratoire pénalise un usage d'exploitation.

Mesure — pas d'observabilité par cas d'usage, donc dimensionnement à l'aveugle.

Ma façon de procéder

Mesurer avant de décider. Profil de charge réel, latence aux percentiles 50, 95 et 99, tokens par cas d'usage, taux d'occupation GPU. Une à deux semaines.

Chercher d'abord les gains sans matériel. Batching continu, quantification, routage par complexité de tâche, cache sémantique, réduction du contexte. C'est là que se trouve l'essentiel, et c'est réversible.

Construire le socle commun en parallèle. System Prompts et gabarits mutualisés, versionnés comme du code ; garde-fous et bornage des agents ; référentiel des cas d'usage tenu au fil de l'eau plutôt qu'après coup.

Faire adopter par les cas d'usage, pas par l'outil. Deux ou trois usages à valeur visible et courte boucle, réussis et documentés, servent ensuite d'exemples. La communauté de référents techniques se construit autour de ces réussites, pas autour d'une formation générique.

Ne dimensionner que ce qui reste, justifié par la mesure et non par l'urgence.

Ce que je souhaite confirmer avec vous

Le parc GPU disponible et le moteur d'inférence en place aujourd'hui.

Les modèles servis, leur nombre et leur variété.

Le profil de charge : pics, concurrence, engagement de latence attendu.

La répartition des usages entre les quatre équipes du GTAR, et leur maturité respective.

Le partage des rôles avec Cœur IA et Connect IA : qui définit le cadre, qui valide l'ouverture d'un cas d'usage, et selon quels critères.

Deux convictions

La première réponse à un problème de charge est rarement d'acheter des GPU. Sur les plateformes Data et IA que j'ai industrialisées, le routage entre modèles, la mise en cache et la maîtrise du contexte ont réduit le coût par requête bien avant tout investissement matériel — et ces leviers se déploient en semaines.

Une solution d'IA n'est adoptée que si quelqu'un en porte l'usage. C'est pourquoi je traite la formation et l'animation de la communauté comme du travail d'ingénierie, pas comme un accompagnement de fin de projet : les gabarits, les garde-fous et la documentation d'exploitation sont ce qui rend l'appropriation possible.