

HAKIM AREZKI, PhD

ARCHITECTE ET LEAD TECHNIQUE IA — PLATEFORMES LLM ON-PREMISE, GPU, KUBERNETES ET LLMOPS

Paris / Île-de-France, Freelance, 06 33 66 12 48, harezki@kiras.fr, Disponible immédiatement

Architecte et lead technique IA, 12 ans d'expérience professionnelle en Data et intelligence artificielle (15 en incluant la recherche doctorale), dont 5 ans dans l'énergie et l'industrie (TotalEnergies) et 8 ans en environnement régulé (BIL, BPCE). Docteur de CentraleSupélec.

Conception, développement et industrialisation de solutions d'IA générative bâties sur des modèles open source — Mistral, LLaMA, Hugging Face — et propriétaires, déployés en environnement maîtrisé, on-premise comme cloud, avec sélection du modèle selon les exigences de qualité, de confidentialité, de latence et de coût.

Opérationnel sur toute la chaîne : paramétrage et optimisation de modèles, prompt engineering avancé et System Prompts mutualisés ; développement d'agents IA avec orchestration, gestion d'état, sélection d'outils, mémoire, garde-fous et validation humaine ; serveurs MCP exposant données et API internes aux agents ; pipelines RAG complets, de l'ingestion à l'évaluation ; industrialisation LLMops sur Docker, Kubernetes et Linux.

Travaille la plateforme comme un service rendu à des équipes GenAI : mise à disposition des modèles, maîtrise de la latence et du coût par requête, routage entre modèles, mise en cache, supervision et dimensionnement du parc. Documentation d'exploitation, modularité et réversibilité systématiques : les plateformes livrées sont conçues pour être tenues par les équipes internes.

Réalisations en IA générative

BIL, Banque Internationale à Luxembourg (depuis 2026) — plateforme Data et IA d'entreprise : architecture multi-LLM intégrant Mistral et LLaMA, pipelines RAG et Document AI, agents IA, serveurs MCP exposant les métadonnées clients issues de Snowflake, System Prompts mutualisés, LLMops, gouvernance de l'IA, RBAC et sécurité au niveau ligne, RGPD, DORA.

TotalEnergies (2020-2025) — industrialisation des cas d'usage d'IA générative à l'échelle du groupe : agents IA, pipelines RAG, Document AI multimodal combinant OCR, vision et LLM. Exposition des données de forage via serveurs MCP pour l'analyse automatisée des rapports journaliers et des incidents d'exploitation par des agents IA.

En amont de l'IA générative, quinze ans de Machine Learning et de Data Science industrialisés en environnement critique : supervision temps réel de mobilité multimodale (RATP, Alstom, Renault, IRT SystemX), détection de criminalité financière et de fraude en banque (BPCE), maintenance prédictive et vision par ordinateur dans l'industrie.

Compétences clés

LLM open source, paramétrage et prompt engineering

Déploiement et exploitation de modèles open source, Mistral, LLaMA, Hugging Face, et propriétaires

Paramétrage et configuration des modèles servis en interne

Sélection du modèle selon la complexité de la tâche, la confidentialité, la latence et le coût

Prompt engineering avancé, conception et mutualisation de System Prompts, gabarits de prompts, versionnement

Sorties structurées et contrôle de cohérence

Garde-fous et réduction des hallucinations

Architecture agentique

Développement d'agents IA, orchestration, gestion d'état, sélection et appel d'outils, mémoire

Model Context Protocol, conception de serveurs exposant données métiers et API internes aux agents

Tool calling et intégration d'API REST

Validation humaine dans la boucle et bornage des exécutions

Observabilité des agents, traces, coût, latence, taux d'échec

Agents documentés, testés et transmissibles

Chaîne RAG complète

Ingestion et parsing documentaire

Découpage et stratégies de chunking

Embeddings et indexation

Recherche vectorielle et hybride BM25

Filtrage par métadonnées et contrôle d'accès au niveau du document

Reranking, génération et post-traitement

Document AI, OCR et modèles vision-langage

Plateforme de service des modèles et exploitation GPU

Mise à disposition de modèles en interne sous forme de service, sélection du moteur de service selon la charge et les contraintes

Batching continu et gestion du cache d'attention pour l'occupation réelle du parc, quantification pour réduire l'empreinte mémoire

Routage entre modèles selon la complexité de la tâche, mise en cache sémantique, repli, maîtrise du coût par requête

Dimensionnement à partir de la mesure : profil de charge, latence p50, p95 et p99, tokens par cas d'usage, taux d'occupation

Priorisation des files et dégradation gracieuse entre usages d'exploration et usages d'exploitation

Conteneurisation Docker et orchestration Kubernetes, déploiement en environnement on-premise maîtrisé

Intégration et déploiement continus pour les modèles, les images et les prompts, GitLab CI et GitHub Actions

Supervision et observabilité : Prometheus, Grafana, OpenTelemetry, Langfuse, MLflow, indicateurs de latence, d'erreur et de consommation

Documentation d'exploitation et transfert aux équipes internes

Évaluation des systèmes IA

Retrieval, Hit Rate, Recall@k, MRR, nDCG

RAG, Context Precision, Context Recall, Faithfulness, Answer Relevancy, RAGAS

LLM, qualité, factualité, taux d'hallucination, latence p50/p95, coût unitaire

Jalons d'évaluation conditionnant la mise en production

Accompagnement, formation et animation de communauté technique

Ateliers de prise en main de l'IA générative et du prompt engineering, construits sur les usages réels des équipes plutôt que sur l'outil

Animation de référents techniques en relais dans les équipes, diffusion des bonnes pratiques et partage des retours d'expérience

Accompagnement des équipes métiers et techniques dans l'adoption des services d'IA, jusqu'à la reprise en autonomie

Conception et animation de six formations professionnelles en Machine Learning, Python, Kafka, ELK et DataViz, SQLI Institute et Fltec

Sensibilisation aux limites des modèles, hallucinations, incohérences, périmètre de validité

Coordination entre équipes aux besoins et aux niveaux de maturité différents, arbitrage entre socle mutualisé et spécificités

Intervenant Big Data Paris

Industrialisation et exploitation

Conteneurisation et orchestration, Docker, Kubernetes, Linux

Routage entre modèles, mise en cache et repli pour maîtriser latence, qualité et coût

Intégration et déploiement continus pour les modèles et les prompts

Supervision, indicateurs p50/p95, taux d'erreur, consommation, coût unitaire

Architecture conçue pour une montée en charge progressive

Sécurité, gouvernance et conformité des cas d'usage

Risques propres aux LLM, hallucinations, injection de prompt, fuite de données, exfiltration par les outils

Contrôle des accès aux outils et aux sources

Garde-fous, validation humaine, auditabilité et traçabilité des sorties

RGPD, DORA, AI Act, classification des cas d'usage par niveau de risque et traduction en contrôles vérifiables

Référencement et documentation des cas d'usage au fil de l'eau, registre des usages, propriétaire, données mobilisées, obligations applicables

RBAC et sécurité au niveau ligne

Documentation, réversibilité et transfert

Documentation d'architecture, des agents et des API

Guides d'exploitation et de maintenance

Conception modulaire et découplage du fournisseur de modèle

Réversibilité, formats portables pour prompts, index et embeddings, protocoles ouverts plutôt que connecteurs propriétaires

Transfert de compétences et reprise en maintenance par les équipes internes

Environnement technique

IA générative : Mistral, LLaMA, Hugging Face, OpenAI, Azure OpenAI, Claude, Amazon Bedrock, Copilot et Copilot Studio

Frameworks et protocoles : LangChain, LlamaIndex, Semantic Kernel, MCP (Model Context Protocol), MLflow, PyTorch, TensorFlow, scikit-learn

RAG et recherche : FAISS, PGVector, OpenSearch, BM25, recherche hybride, reranking, RAGAS

Document AI : Azure Document Intelligence, modèles vision-langage, Docling, Tesseract, OpenCV

Infrastructure : Linux, Docker, Kubernetes, GPU, Terraform, GitLab CI/CD, GitHub Actions, Bash, Python

Observabilité : Langfuse, Arize, OpenTelemetry, Prometheus, Grafana, MLflow

Data : Snowflake, Databricks, dbt, Python, SQL, Spark, PySpark, Kafka, Airflow

API : FastAPI, API REST, architectures événementielles

Versionnage : Git

Expérience professionnelle

Architecte et Lead technique IA — BIL, Banque Internationale à Luxembourg

Janvier 2026 à aujourd'hui

Conception, développement et exploitation de GENIA, plateforme Data et IA d'entreprise mettant à disposition des domaines métiers des capacités d'IA générative gouvernées, en environnement bancaire régulé.

Architecture et exploitation d'une plateforme multi-LLM intégrant plusieurs modèles propriétaires et open source, notamment Mistral et LLaMA, sélectionnés selon les exigences de qualité, de confidentialité, de coût et de latence.

Développement des mécanismes de routage, de mise en cache et de repli permettant de maîtriser la latence, la qualité et le coût des requêtes, avec suivi des indicateurs p50/p95, du taux d'erreur, de la consommation et du coût unitaire.

Conception et développement de serveurs MCP exposant les métadonnées clients issues de Snowflake, pour leur extraction et leur exploitation par les agents IA de la plateforme.

Développement d'agents IA interrogeant les modèles, les bases documentaires et les API internes, avec gestion d'état, sélection d'outils, garde-fous et validation humaine sur les actions sensibles.

Construction de pipelines RAG et Document AI : ingestion, parsing, chunking, embeddings, indexation, recherche hybride, reranking, génération — avec filtrage par métadonnées et contrôle d'accès au niveau du document.

Conception des System Prompts mutualisés et des gabarits réutilisables, versionnés au même titre que le code, avec sorties structurées et contrôles de cohérence.

Mise en place du cadre d'évaluation : métriques de retrieval, métriques RAG et suivi de la factualité, du taux d'hallucination, de la latence et du coût, avec jalons conditionnant le passage en production.

Industrialisation LLMops : conteneurisation, déploiement continu des modèles et des prompts, observabilité et supervision.

Traitement des risques propres à l'IA : hallucinations, injection de prompt, contrôle des accès aux outils, auditabilité et traçabilité des sorties.

Conformité RBAC, sécurité au niveau ligne, chiffrement, RGPD et exigences bancaires dont DORA.

Coordination d'équipes pluridisciplinaires réunissant experts Data, IA, architecture, ingénierie et DevOps.

Architecte et Lead technique Data & IA — TotalEnergies

Décembre 2020 à décembre 2025

Industrialisation à l'échelle du groupe des cas d'usage Machine Learning et IA générative, sur une plateforme Data d'entreprise servant plusieurs domaines métiers : opérations industrielles, distribution, ressources humaines.

Industrialisation d'une quinzaine de cas d'usage Data, Machine Learning et IA, de l'expérimentation à la production : opérations industrielles, maintenance prédictive, vision par ordinateur, Document AI et IA générative.

Conception et développement de serveurs MCP exposant les données de forage, permettant à des agents IA d'analyser automatiquement les rapports journaliers et les incidents d'exploitation.

Conception et industrialisation de pipelines Document AI, OCR et RAG pour le traitement de corpus documentaires techniques et opérationnels.

Développement d'agents IA et de solutions multimodales combinant OCR, vision et LLM pour l'automatisation documentaire et l'aide à la décision.

Développement des pipelines d'entraînement, d'évaluation et de déploiement intégrant MLflow, intégration et déploiement continus, supervision et versionnement.

Construction des pipelines Data sur Databricks, PySpark, Airflow et dbt, et des architectures événementielles Kafka.

Industrialisation de l'infrastructure via Terraform, Docker et pipelines de déploiement continu, avec observabilité et optimisation des performances.

Définition des standards d'architecture, des décisions structurantes formalisées en ADR et des pratiques MLOps du groupe, et diffusion auprès des équipes des différentes entités.

Encadrement d'une équipe pluridisciplinaire d'une vingtaine de personnes réunissant métiers, Data Engineering, Data Science, architecture, cloud et DevOps.

Accompagnement des équipes métiers dans l'adoption des services d'IA : ateliers de prise en main, gabarits de prompts mutualisés, guides d'exploitation, et transfert des solutions aux équipes internes.

Lead technique Data et IA, programme MSM — RATP, avec Alstom, Renault et IRT SystemX

Août 2018 à décembre 2020

Programme de mobilité multimodale réunissant plusieurs partenaires industriels et un institut de recherche technologique.

Conception d'architectures en microservices pour la supervision temps réel et la gestion des incidents.

Construction et déploiement d'un lac de données multi-couches pour l'ingestion, le traitement et l'analyse à l'échelle, avec intégration de flux Kafka sécurisés.

Développement de modèles prédictifs pour les flux voyageurs, la durée des incidents et la planification opérationnelle.

Mise en œuvre de la détection d'anomalies et de l'analyse de journaux pour la qualité des données et la conformité.

Livraison d'un démonstrateur opérationnel de supervision de mobilité déployé à Paris-La Défense.

Formation des équipes métiers et techniques aux plateformes d'IA et à la visualisation de données.

Publication IEEE (DSD 2020) sur l'architecture de supervision hybride temps réel et prédictif.

Lead Data Science et gouvernance — BPCE, banque et assurance

Janvier 2017 à août 2018

Lutte contre le blanchiment et le financement du terrorisme, criblage des sanctions et embargos, détection de fraude, conformité RGPD des traitements financiers.

Construction d'un moteur de détection de fraude de bout en bout et automatisation des flux de gestion des alertes, sanctions et embargos.

Développement d'un moteur de matching exact, flou et phonétique entre entités suspectes et clients.

Réduction des faux positifs par TF-IDF, vectorisation par hachage et analyse des matrices de confusion.

Déploiement du dictionnaire de données d'entreprise et du lignage sur Apache Atlas et ELK.

Mise en conformité RGPD des chaînes de traitement : contrôle d'accès, traçabilité, protection des données.

Lead Data Science — Distribution de luxe

Septembre 2015 à janvier 2017

Construction d'un moteur d'intelligence client : classification des profils, prédiction de comportement, modélisation de l'attrition, moteur de recommandation par filtrage collaboratif.

Migration de bases relationnelles vers NoSQL et capture de flux asynchrones via Kafka.

Industrialisation et refactorisation du code des modèles pour la mise à l'échelle.

Data Scientist — Beamlabs / Française des Jeux

Novembre 2014 à septembre 2015

Construction d'un socle Big Data pour le marketing temps réel : architecture distribuée, ingestion en flux, indexation ElasticSearch.

Développement d'un moteur de recommandation temps réel et de modèles de marketing prédictif.

Ingénieur R&D, doctorat — CentraleSupélec, Université Paris-Saclay

Février 2010 à octobre 2014

Application du Machine Learning à l'optimisation de cellules photovoltaïques et à la modélisation de transistors.

Développement d'algorithmes de simulation et d'analyse de données scientifiques.

Formation

Doctorat, CentraleSupélec — Université Paris-Saclay, Orsay, 2011-2014 Master of Sciences, Université Pierre et Marie Curie, Paris VI, 2010-2011 Maîtrise en Sciences de l'ingénieur, Université Paris Diderot, Paris VII, 2009-2010

Publications et interventions

18 articles scientifiques publiés dans des revues internationales, 7 participations à des conférences, *Architecture of a Public Transport Supervision System Using Hybridization Models Based on Real and Predictive Data*, DSD 2020, Intervenant Big Data Paris 2018

Langues

Français bilingue, Anglais courant