

HAKIM AREZKI, PhD

ARCHITECTE IA ET IA GÉNÉRATIVE — LLM, RAG ET AGENTS

Paris / Île-de-France · Freelance · 06 33 66 12 48 · harezki@kiras.fr · Disponible immédiatement

Architecte et lead technique IA, 12 ans d'expérience (15 en incluant la recherche doctorale) en Data et intelligence artificielle, dont 8 ans en services financiers régulés (BIL, BPCE) et en grands groupes industriels (TotalEnergies, RATP). Docteur de CentraleSupélec.

Conception et exploitation de GENIA, plateforme Data et IA sécurisée en environnement bancaire : capacités d'IA générative, de LLM et d'agents mises à disposition sous forme de produits gouvernés, permettant aux domaines métiers de construire et d'exploiter leurs cas d'usage à l'échelle.

Opérationnel sur l'ensemble de la chaîne : orchestration multi-LLM avec routage, mise en cache, repli et maîtrise de la latence ; pipelines RAG et Document AI ; agents IA ; industrialisation LLMops et MLOps ; intégration par API et par événements ; gouvernance de l'IA couvrant les politiques d'accès, la sélection des modèles, le risque d'hallucination, la confidentialité et l'auditabilité.

Socle Data solide (Snowflake, Databricks, dbt, Power BI) garantissant que les capacités d'IA sont alimentées par des données d'entreprise gouvernées, fiables et sécurisées plutôt que par des pipelines isolés.

Réalisations IA en environnement régulé

BIL, Banque Internationale à Luxembourg (depuis 2026) : plateforme Data et IA d'entreprise, maillage multi-LLM, RAG et Document AI, agents IA, LLMops, gouvernance de l'IA, RBAC et sécurité au niveau ligne, RGPD, DORA.

TotalEnergies (2020-2025) : industrialisation à l'échelle du groupe des cas d'usage Machine Learning et IA générative, agents IA, Document AI, pipelines RAG, MLOps et LLMops.

RATP, programme MSM (2018-2020) : modèles prédictifs, vision par ordinateur et OCR, architectures temps réel pour la supervision de mobilité multimodale.

BPCE (2017-2018) : détection de criminalité financière par IA — blanchiment, financement du terrorisme, criblage sanctions et embargos, fraude — catalogue et lignage d'entreprise, conformité RGPD.

Compétences clés

Architecture de plateformes IA et agentiques

Architecture de plateformes d'IA agentique : orchestration, appel d'outils, mémoire, garde-fous · Orchestration multi-LLM, routage de modèles, mise en cache, repli et maîtrise de la latence · RAG, recherche hybride, reranking et pipelines Document AI · Intégration à la couche de données d'entreprise et aux applications métiers · Connecteurs, API et patterns d'intégration événementielle

Industrialisation du cycle de vie IA

Déploiement et exploitation de modèles propriétaires et open source · Cycle de vie des modèles : déploiement, supervision, réentraînement · Versionnement, intégration et déploiement continus pour les modèles et les prompts · Cadres d'évaluation : RAGAS, Hit Rate, MRR, Recall@k, nDCG · Supervision de la performance, de l'usage, du coût et de la fiabilité · Déploiement en production à l'échelle

Machine Learning et Data Science

Modèles prédictifs et de classification · Traitement automatique du langage, vision par ordinateur et OCR · Séries temporelles et prévision · Détection d'anomalies · Moteurs de recommandation · Industrialisation et mise à l'échelle du code des modèles

Gouvernance, risque et conformité de l'IA

Cadres de gouvernance : politiques d'accès, sélection et approbation des modèles, règles d'usage · Maîtrise du risque : hallucinations, garde-fous, validation humaine dans la boucle, risque de modèle · Confidentialité des données et contraintes réglementaires : RGPD, DORA, vigilance sur le règlement européen sur l'IA · Sécurité et gestion des identités pour les usages d'IA · Auditabilité et traçabilité des sorties

Mise à disposition et adoption

Catalogue de composants réutilisables : agents, prompts, API, gabarits · Expérience développeur et utilisateur · Intégration des domaines métiers et promotion de l'adoption · Formation des équipes métiers et techniques

Leadership technique

Encadrement d'équipes plateforme pluridisciplinaires d'une vingtaine de personnes · Gouvernance d'architecture, décisions structurantes et standards techniques · Dialogue avec des sponsors métiers et dirigeants · Équilibre entre innovation, coût et risque · Livraison Agile : Scrum, Kanban, SAFe, Jira, Confluence

Environnement technique

IA et IA générative : OpenAI, Azure OpenAI, Microsoft Copilot et Copilot Studio, Claude, Mistral, LLaMA, Hugging Face, RAG, agents IA, Document AI · Frameworks : LangChain, LlamaIndex, Semantic Kernel, MLflow, Dataiku, PyTorch, TensorFlow, scikit-learn · RAG et recherche vectorielle : FAISS, PGVector, BM25, recherche hybride, reranking, RAGAS · Document AI : Azure Document Intelligence, modèles vision-langage, Docling, Tesseract, OpenCV · MLOps et observabilité : MLflow, OpenTelemetry, Prometheus, Grafana, Langfuse, Arize · Plateformes Data et Cloud : Snowflake, Databricks, dbt, Azure, GCP, AWS · Data Engineering : Python, SQL, Spark, PySpark, Kafka, Airflow · API et intégration : FastAPI, API REST, Redis Streams, architectures événementielles · Infrastructure : Docker, Kubernetes, Terraform, GitHub Actions, Azure DevOps, GitLab CI/CD

Expérience professionnelle

Responsable de programme Data et IA — BIL, Banque Internationale à Luxembourg

Janvier 2026 à aujourd'hui

Pilotage de la conception, de l'industrialisation et de l'exploitation de GENIA, la plateforme Data et IA d'entreprise de la banque, mettant à disposition des domaines métiers des capacités d'IA générative gouvernées et mutualisées, dans un environnement bancaire régulé.

Contribution à la vision, à l'architecture cible et au modèle opérationnel de la plateforme, en traitant les capacités d'IA comme des produits réutilisables plutôt que comme des cas d'usage isolés.

Traduction des priorités métiers en feuille de route et en portefeuille de capacités, priorisé avec les parties prenantes métiers et informatiques.

Définition des indicateurs de pilotage de la plateforme : usage, performance, adoption et coût des services d'IA (FinOps).

Pilotage FinOps de la maîtrise et de l'optimisation des coûts de consommation des modèles et des API, incluant les stratégies de sélection, de routage et de mise en cache.

Pilotage de la modernisation du décisionnel historique IBM Cognos vers Snowflake et Power BI : inventaire et rationalisation du portefeuille de rapports, refonte des modèles de données, reconstruction de la couche sémantique, réconciliation, tests de performance et accompagnement des utilisateurs.

Contribution au cadre de gouvernance de l'IA : politiques d'accès, sélection et approbation des modèles, règles d'usage, alignement avec les instances Data et Digital de la banque.

Traitement des risques spécifiques à l'IA : maîtrise des hallucinations, garde-fous, validation humaine dans la boucle, jalons d'évaluation avant mise en production.

Conformité aux contraintes de confidentialité et réglementaires : RBAC, sécurité au niveau ligne, RGPD, chiffrement, traçabilité et auditabilité, en cohérence avec les exigences bancaires dont DORA.

Coordination des parties prenantes Data, ingénierie, architecture, IA, DevOps et métiers, et pilotage des partenaires technologiques.

Responsable Data et IA, plateforme d'entreprise — TotalEnergies

Décembre 2020 à décembre 2025

Industrialisation à l'échelle du groupe des cas d'usage Machine Learning et IA générative, sur une plateforme Data d'entreprise servant plusieurs domaines métiers : distribution, ressources humaines, opérations industrielles.

Encadrement d'équipes pluridisciplinaires d'une vingtaine de personnes réparties entre métiers, Data Engineering, Data Science, architecture, cloud et DevOps.

Pilotage des partenaires et prestataires externes contribuant à la livraison de la plateforme et des cas d'usage.

Accompagnement du passage des cas d'usage de l'expérimentation à la production, avec les pratiques MLOps et LLMOps associées : intégration et déploiement continu, supervision, évaluation, observabilité et amélioration continue.

Contribution à la conception et à l'évolution de la plateforme Data d'entreprise sur Snowflake, en support de plusieurs domaines métiers et de volumes hétérogènes importants.

Définition des standards techniques et d'architecture : modélisation des données, MDM, API, gouvernance, sécurité et intégration à la plateforme.

Traduction des besoins métiers en produits de données réutilisables et en capacités de plateforme.

Contribution aux initiatives de gestion des données de référence et mise en œuvre des pratiques de qualité, gouvernance, lignage et contrôle d'accès.

Accompagnement de l'adoption et de l'évolution continue des services d'IA, des produits de données et des capacités décisionnelles dans l'organisation.

Responsable Data, programme MSM — RATP, avec Alstom, Renault et IRT SystemX

Août 2018 à décembre 2020

Direction des initiatives Data et IA d'un programme de mobilité multimodale réunissant plusieurs partenaires industriels et un institut de recherche technologique.

Pilotage des initiatives Data et IA du programme, du cadrage des cas d'usage à la conception d'architecture jusqu'au déploiement en production.

Management des équipes internes et externes — ingénieurs IA, data scientists, développeurs : définition du périmètre, planification des ressources, alignement de la feuille de route, gouvernance technique et standards de livraison.

Conception d'architectures en microservices pour la supervision temps réel et la gestion des incidents.

Construction et déploiement d'un lac de données multi-couches sur Azure pour l'ingestion, le traitement et l'analyse à l'échelle.

Développement de modèles prédictifs pour les flux voyageurs, la durée des incidents et la planification opérationnelle.

Mise en œuvre de la détection d'anomalies et de l'analyse de journaux pour garantir la qualité des données et la conformité réglementaire.

Formation des équipes métiers et techniques aux plateformes d'IA, à la visualisation de données et à l'automatisation des processus.

Livraison de démonstrateurs fonctionnels de supervision de mobilité intelligente à La Défense.

Responsable Data Science et gouvernance — BPCE, banque et assurance

Janvier 2017 à août 2018

Programme Data et IA au sein d'un grand groupe bancaire et d'assurance, couvrant la lutte contre le blanchiment et le financement du terrorisme, le criblage des sanctions et embargos, la détection de fraude et la conformité RGPD des traitements de données financières.

Pilotage de la construction d'un moteur de détection de fraude de bout en bout et de l'automatisation des flux de gestion des alertes, sanctions et embargos.

Conception et déploiement du dictionnaire de données d'entreprise et de la capacité de lignage sur Apache Atlas, établissant la traçabilité des actifs de données financières depuis les systèmes sources jusqu'au reporting réglementaire.

Structuration des métadonnées, de la propriété et des définitions de données sur les domaines LCB-FT, sanctions et fraude.

Mise en conformité RGPD des chaînes de traitement de données financières : contrôle d'accès, traçabilité et protection des données.

Définition et suivi des indicateurs de performance des systèmes de détection, suivis comme des engagements de service, avec restitution aux équipes risque et conformité.

Animation de la démarche Agile adaptée à une livraison Data en environnement bancaire : lancement, comités de pilotage, rétrospectives, recette et revues de mise en production.

Responsable Data Science — Distribution de luxe

Septembre 2015 à janvier 2017

Construction d'un moteur d'intelligence client : classification des profils, prédiction de comportement, modélisation de l'attrition et de la rétention, moteur de recommandation.

Définition et suivi des indicateurs de performance retail, avec restitution temps réel aux équipes métiers.

Industrialisation du code des modèles pour la mise à l'échelle et le déploiement.

Data Scientist — Beamlabs / Française des Jeux

Novembre 2014 à septembre 2015

Construction d'un socle Big Data pour le marketing temps réel : architecture distribuée, ingestion en flux, indexation.

Développement d'un moteur de recommandation temps réel et de modèles de marketing prédictif.

Ingénieur R&D, doctorat — CentraleSupélec et École Polytechnique

Février 2010 à octobre 2014

Application du Machine Learning à l'optimisation de performance de cellules photovoltaïques et à la modélisation de transistors ; analyse de marché de l'expansion du photovoltaïque en Europe.

Développement d'algorithmes de simulation et d'analyse de données, et visualisation scientifique.

Formation

Doctorat, CentraleSupélec, Université Paris-Saclay, Orsay (2011-2014)

Master of Sciences, Université Pierre et Marie Curie, Paris VI (2010-2011)

Maîtrise en Sciences de l'Ingénieur, Université Paris Diderot, Paris VII (2009-2010)

Langues

Français : langue maternelle

Anglais : courant professionnel

Allemand : notions

Publications et interventions

Architecture of a Public Transport Supervision System Using Hybridization Models Based on Real and Predictive Data, IEEE / DSD 2020, p. 440-446

Disruption Impact on the Offer and Demand on the Public Transport Network in Paris

Big Data Paris 2018, conférencier : « We can tell you by what external context your sales are influenced »

Formations dispensées

Python avancé pour le Machine Learning (SQLI Institute, 2019) · Datalab (Saagie, 2019) · SQL for Data Science (Fitec, 2018) · ELK (Fitec, 2017) · Kafka (Air4Data / SQLI Institute, 2017) · DataViz, Tableau et Power BI (SQLI Institute, 2017)