

HAKIM AREZKI, PhD

CONSULTANT DATA ET BI — POWER BI, SNOWFLAKE, DATAIKU, ETL

Paris / Île-de-France · Freelance · 06 33 66 12 48 · harezki@kiras.fr · Disponible immédiatement

Consultant Data et décisionnel, 12 ans d'expérience (15 en incluant la recherche doctorale) dans la conception, la migration et l'exploitation de plateformes Data et BI d'entreprise, en environnement régulé bancaire et financier (BIL, BPCE) et en grands groupes industriels (TotalEnergies, RATP).

Modernisation de patrimoines décisionnels historiques vers le cloud : inventaire et rationalisation du portefeuille de rapports, refonte des modèles de données, industrialisation des pipelines de transformation, reconstruction de la couche sémantique, sécurité au niveau ligne, réconciliation et accompagnement des utilisateurs.

Maîtrise de la chaîne complète, de l'ingestion à la restitution : ETL et ELT, modélisation, couches de données de confiance, modèles sémantiques, tableaux de bord et indicateurs métiers, self-service et gouvernance du décisionnel.

Analyse et valorisation de la donnée : définition et suivi d'indicateurs métiers, analyses exploratoires, modèles prédictifs et automatisation de traitements analytiques.

Compétences clés

Power BI et restitution

Modèles sémantiques, Power Query et mesures DAX · Indicateurs métiers et tableaux de bord opérationnels · Sécurité au niveau ligne et accès gouvernés · Administration Power BI Cloud : espaces de travail, capacités, pipelines de déploiement, passerelles, stratégie de rafraîchissement · Migration de patrimoines décisionnels historiques depuis IBM Cognos · Activation du self-service, gouvernance du décisionnel et certification des jeux de données

ETL, ELT et ingénierie de données

Frameworks d'ingestion batch et streaming · Industrialisation des pipelines de transformation avec dbt et Spark · Orchestration avec Airflow · Ingestion temps réel avec Kafka · Outils ETL : Talend, Sqoop · Modélisation de données et couches curées de confiance · Optimisation des performances et des coûts de traitement

Snowflake et plateformes Data

Architecture de plateforme Data d'entreprise sur Snowflake · Modélisation et couches de données de confiance · Dimensionnement des entrepôts, moniteurs de ressources, suivi de consommation, optimisation des requêtes et allocation des coûts par domaine · Databricks, PySpark et traitement distribué

Dataiku et analytique

Conception et industrialisation de flux analytiques sous Dataiku · Passage des prototypes à la production · Analyses exploratoires et statistiques · Modèles prédictifs : classification, prévision, détection d'anomalies, attrition et recommandation · Automatisation de traitements analytiques récurrents

Qualité, gouvernance et conformité des données

Qualité de données, réconciliation et contrôles · Gestion des données de référence · Catalogue, dictionnaire de données et lignage avec Apache Atlas · Contrôle d'accès RBAC et sécurité au niveau ligne, masquage et chiffrement · RGPD, DORA, auditabilité et traçabilité

Relation métier et delivery

Recueil et analyse des besoins métiers · Traduction en produits de données réutilisables · Formation et accompagnement des utilisateurs · Livraison Agile : Scrum, Kanban, SAFe, Jira, Confluence

Environnement technique

Décisionnel : Power BI Cloud, modèles sémantiques, Power Query, DAX, sécurité au niveau ligne, espaces de travail, pipelines de déploiement · IBM Cognos comme patrimoine source · Grafana · Plateformes Data : Snowflake, Databricks, dbt, Azure, GCP, AWS · Analytique : Dataiku, Python, scikit-learn, H2O · ETL et intégration : Talend, Sqoop, Airflow, Kafka, Redis Streams, API REST · Langages et traitement : Python, SQL, Spark, PySpark, R · Bases de données : Snowflake, PostgreSQL, Oracle SQL, MongoDB, Cassandra, HBase, Redis · Recherche et logs : Elasticsearch, Logstash, Kibana · Gouvernance : MDM, qualité de données, lignage, catalogue, Apache Atlas, RBAC, RLS, RGPD · DevOps : Docker, Kubernetes, GitLab CI/CD, Azure DevOps

Expérience professionnelle

Responsable Data et BI — BIL, Banque Internationale à Luxembourg

Janvier 2026 à aujourd'hui

Modernisation du patrimoine décisionnel de la banque et exploitation de la plateforme Data et IA d'entreprise, sur un socle Snowflake.

Pilotage de la migration du décisionnel historique IBM Cognos vers Snowflake et Power BI : inventaire et rationalisation du portefeuille de rapports, des packages, des modèles de données et des règles de gestion.

Refonte des modèles de données et des pipelines de transformation alimentant le décisionnel.

Reconstruction des modèles sémantiques sous Power BI : Power Query, mesures DAX, sécurité au niveau ligne.

Réconciliation des données et tests de performance entre l'ancien et le nouveau patrimoine.

Accompagnement et formation des utilisateurs, mise en place de la gouvernance du décisionnel.

Conception et évolution des capacités Snowflake fournissant des données gouvernées et fiables à l'analytique, au Machine Learning et aux cas d'usage d'IA.

Industrialisation de cas d'usage Data Science et IA sous Dataiku et Snowflake, du prototype à la production.

Mise en conformité : RBAC, sécurité au niveau ligne, RGPD, chiffrement, traçabilité et auditabilité, en cohérence avec les exigences bancaires dont DORA.

Travail avec les équipes Data Engineering sur les pipelines d'ingestion, de transformation et d'intégration alimentant l'analytique et les charges d'IA.

Responsable Data et plateforme analytique — TotalEnergies

Décembre 2020 à décembre 2025

Plateforme Data d'entreprise sur Snowflake au service de plusieurs domaines métiers : distribution, ressources humaines, opérations industrielles.

Conception et maintenance des jeux de données, tableaux de bord et indicateurs Power BI utilisés par les équipes métiers pour le pilotage opérationnel et la décision.

Activation du self-service analytique sur des jeux de données gouvernés.

Conception et industrialisation de pipelines de données à l'échelle avec Databricks, PySpark, dbt, Airflow et Kafka, couvrant l'ingestion batch et streaming.

Travail sur l'architecture de données Snowflake, la modélisation et les couches de données de confiance alimentant l'analytique, le reporting, les processus opérationnels et les cas d'usage d'IA.

Traduction des besoins métiers distribution et ressources humaines en produits de données réutilisables.

Contribution aux initiatives de gestion des données de référence et mise en œuvre des pratiques de qualité, gouvernance, lignage et contrôle d'accès.

Industrialisation de cas d'usage Machine Learning sur Databricks et MLflow, de l'expérimentation à la production.

Coordination d'équipes pluridisciplinaires d'une vingtaine de personnes et pilotage de prestataires externes.

Responsable Data — RATP, programme MSM avec Alstom, Renault et IRT SystemX

Août 2018 à décembre 2020

Construction et déploiement d'un lac de données multi-couches sur Azure pour l'ingestion, le traitement et l'analyse à l'échelle.

Développement et maintenance de tableaux de bord Power BI, d'interfaces web et d'indicateurs opérationnels améliorant le pilotage.

Développement de modèles prédictifs pour les flux voyageurs, la durée des incidents et la planification opérationnelle.

Construction de pipelines OCR et de vision par ordinateur pour le traitement automatisé de données non structurées.

Mise en œuvre de la détection d'anomalies et de l'analyse de journaux pour garantir la qualité des données et la conformité réglementaire.

Formation des équipes métiers et techniques à la visualisation de données et à l'automatisation des processus.

Responsable Data Science et gouvernance — BPCE, banque et assurance

Janvier 2017 à août 2018

Conception et déploiement du dictionnaire de données d'entreprise et de la capacité de lignage sur Apache Atlas, établissant la traçabilité des actifs de données financières jusqu'au reporting réglementaire.

Structuration des métadonnées, de la propriété et des définitions de données sur les domaines conformité, sanctions et fraude.

Définition d'indicateurs de performance des systèmes de détection et livraison de tableaux de bord Power BI pour les équipes risque et conformité.

Réduction significative des faux positifs par analyse de matrice de confusion et modèles de classification.

Déploiement de grappes Elasticsearch et Kibana pour l'indexation de journaux à grande échelle et l'investigation des alertes.

Mise en conformité RGPD des chaînes de traitement de données financières.

Responsable Data Science — Distribution de luxe

Septembre 2015 à janvier 2017

Intégration de données CRM et transactionnelles d'Oracle SQL vers Cassandra via Sqoop, capture de flux temps réel avec Kafka, enrichissement par données externes.

Définition et suivi d'indicateurs retail — ventes par catégorie, taux de retour, attrition, fréquence de visite — avec restitution temps réel sous Spark, Storm et Power BI.

Construction d'un moteur d'intelligence client : classification, prédiction de comportement, attrition et recommandation.

Data Scientist — Beamlabs / Française des Jeux

Novembre 2014 à septembre 2015

Construction d'un socle Big Data pour le marketing temps réel : architecture Hadoop et HBase distribuée, ingestion en flux Kafka, ingestion Talend vers Elasticsearch.

Développement d'un moteur de recommandation temps réel et de modèles prédictifs à partir de l'analyse comportementale.

Enrichissement des données internes par collecte web distribuée : météo, géolocalisation, données socio-démographiques.

Ingénieur R&D, doctorat — CentraleSupélec et École Polytechnique

Février 2010 à octobre 2014

- Application du Machine Learning à l'optimisation de cellules photovoltaïques et à la modélisation de transistors.
- Développement d'algorithmes de simulation et d'analyse de données en Python et R, visualisation scientifique avec R-Shiny. ## Formation
- Doctorat, CentraleSupélec, Université Paris-Saclay, Orsay (2011-2014)
- Master of Sciences, Université Pierre et Marie Curie, Paris VI (2010-2011)
- Maîtrise en Sciences de l'Ingénieur, Université Paris Diderot, Paris VII (2009-2010)

Langues

Français : langue maternelle

Anglais : courant professionnel

Allemand : notions

Publications et interventions

Architecture of a Public Transport Supervision System Using Hybridization Models Based on Real and Predictive Data, IEEE / DSD 2020, p. 440-446

Disruption Impact on the Offer and Demand on the Public Transport Network in Paris

Big Data Paris 2018, conférencier : « We can tell you by what external context your sales are influenced »

Formations dispensées

Python avancé pour le Machine Learning (SQLI Institute, 2019) · Datalab (Saagie, 2019) · SQL for Data Science (Fitec, 2018) · ELK (Fitec, 2017) · Kafka (Air4Data / SQLI Institute, 2017) · DataViz, Tableau et Power BI (SQLI Institute, 2017)